



TRAST: 面向资产截面与时序择时的 Transformer 强化学习框架

经济与管理学院 管理科学与工程系

汇报人：陈实 指导老师：高宝俊 教授

2026 年 5 月

研究背景与意义

➤ 研究背景

量化研究：利用概率统计知识从海量金融数据中挖掘信号，执行交易，获取盈利

量化因子：一串具有金融学意义的数学公式，本质是对于未来收益的预测

主要关心两个问题：（1）截面选股（以股票市场为例） （2）择时（何时买卖）

➤ 传统因子研究的局限

量化策略极度依赖人工因子挖掘经验，虽然可解释性较强，但无法实现端到端交易


➤ 传统模型研究的局限

1. 时序预测模型：
 - （1）传统的深度学习架构（如RNN）：序贯学习难以有效刻画资产间的横截面关联
 - （2）注意力机制：高精度预测未必能够转化成投资组合的稳定收益
2. 强化学习模型：构建交易策略环境困难，需要极强的数据表征学习

研究背景与意义

➤ 研究意义：

参照大模型训练流程，提出结合表征学习与强化学习的两阶段端到端交易框架——TRAST



研究方法 基础模型概述

➤ Transformer架构概述


基于传统Transformer架构及业界拓展架构 (Llama) 共构建了**四种**高效变体, 均会在后续的两阶段框架进行回测验证

1. baseline (MHA+PE+FFN)

2. MHA+RoPE+MoE

3. MQA+RoPE+MoE

4. GQA+RoPE+MoE



研究方法 第一阶段：表征学习


➤ MAE预训练

(Maskd Autoencoder)

- 1.不直接进行收益预测
- 2.随机掩码50%技术指标
- 3.重构被掩码特征

➤ 目的

模拟大模型预训练过程
学习数据本身的特征交互



研究方法 第一阶段：表征学习

➤ 预测微调

1. 构建长短期预测标签


2. 均方误差损失优化

3. 排序损失优化

(希望模型预测的排序
与真实收益的排序保持一致)

➤ 目的

模拟大模型的监督微调过程
学会预测未来的收益率



研究方法 第二阶段：策略学习

➤ 策略学习

改进的SAC算法：

1.最大化资产净值

2.最大化策略熵


3.三层损失函数优化

➤ 独特创新点

1.预训练迁移学习

2.持续自监督学习

3.层次化特征学习



实验分析

➤ 数据集

数据来源：CSI300中的88只股票

数据划分：

- (1) 训练集：2011年4月至 2018年12月
- (2) 验证集：2019年1月至 2021年12月
- (3) 测试集：2022年1月至 2022年5月

➤ 回测指标

年化收益率、夏普比率、卡玛比率等等


➤ 回测结果

MQA+RoPE+MoE模型最优


验证集 年化收益率76.36%，夏普比率1.90

测试集 年化收益率159.96%，夏普比率3.08

验证集资产净值曲线



测试集资产净值曲线



总结与展望

➤ 总结

- 1.理论创新：首个MAE预训练+RL两阶段交易框架
- 2.算法创新：MAE-SAC持续自监督强化学习
- 3.实践价值：实现较高的年化收益率与夏普比率，非常优秀的低频策略

➤ 展望

- 1.引入基本面、另类数据，丰富数据表征
- 2.考虑多市场联合优化，不局限于股市
- 3.实盘交易验证



武汉大学经济与管理学院

Economics and Management School of Wuhan University

敬请各位老师批评指正！

经济与管理学院 管理科学与工程系

汇报人：陈实

指导老师：高宝俊 教授

2026 年 5 月